

Yöntem, Model ve Veri Seti Kararları

Bu belge, sistemde hangi algoritma/modelin kullanıldığını, bu modellerin neden alternatiflerine tercih edildiğini, kullanılan veri setini ve ön/ardıl işlem adımlarını özetler.

1. Obje Tespiti — YOLOE-26 + LVIS

Model: Açık kaynaklı YOLOE-26 modeli tercih edilmiştir. Standart bir sınıflandırıcı gibi sabit bir sınıf listesine eğilmek yerine, hangi sınıfları arayacağı çalışma zamanında (`model.set_classes(...)`) metin olarak verilir.

Neden YOLOE-26: YOLOE modeli, eğitime ihtiyaç duymadan çalışma zamanında verilen metinle verimli çalışabildiği için tercih edilmiştir. Sürüm numarasının 26 olması, model sağlayıcısının bu sürümle birlikte yeni özellikler getirip çalışma performansını artırmasından kaynaklanmaktadır. L boyutunun seçilme nedeni ise, diğer boyutlarla yapılan karşılaştırmalı testler sonucunda en doğru ve en performanslı sonucu veren model olmasıdır.

YOLOE-26'nın alternatif modellerden farkı: Standart YOLO'nun sınıf listesi eğitim sırasında sabitlenirken, YOLOE aynı model mimarisini koruyup bu listeyi çalışma zamanında metinle tanımlanabilir hale getiriyor. ResNet ve CLIP gibi sınıflandırma modelleri görselde tespit edilen objenin konum bilgisini vermiyor; Faster R-CNN, SSD, RetinaNet gibi dedektörlerin sınıf listesi eğitimde belirleniyor; DETR gibi transformer tabanlı dedektörler CPU'da ağır çalışıyor; Grounding DINO ve YOLO-World benzer fikri taşısa da genelde daha ağır; V3Det ise geniş sözlüğüne rağmen farklı bir eğitim altyapısı gerektiriyor. Bu sebeplerden dolayı, proje mimarisine ve çözüm fikrine en uygun model olan YOLOE-26 tercih edilmiştir.

Neden sıfırdan model eğitilmedi: Ana sebep, bu veri setiyle eğitim yapabilecek yeterli donanımına sahip olunmamasıdır. LVIS'in 1205 sınıfını tanıyan hazır bir ağırlık yayımlanmış değildir; ücretsiz Colab üzerinden yapılacak sıfırdan bir eğitimin süresi de projenin yapım süresiyle örtüşmemektedir. Sınıf sayısı daha düşük bir veri setiyle eğitim yapılabilirdi, ama bu durumda projenin hedeflediği genel çözüm kriteri sağlanamazdı.

2. Öne Çıkan Objeyi Seçme Problemi — Kural Tabanlı Skor Algoritması

Görselde birden fazla obje varsa, hangisinin öne çıktığı bir modele değil, basit bir algoritmaya dayanılarak belirleniyor. Bu formülün yeterli ayrımı sağladığı görüldüğü için ayrı bir model kullanılmasına gerek duyulmadı:

temel skor = $0.7 \times \sqrt{\text{objenin görseldeki alan oranı}} + 0.3 \times \text{tespit güveni}$

skor = temel skor $\times 0.45$ (obje bir taşıyıcı yüzey ya da bir kapsa)
temel skor (diğer tüm durumlarda)

Alan oranına karekök uygulanmasının nedeni, alanın kenar uzunluğunun karesiyle büyümesi — karekök bunu algıya daha yakın bir ölçeğe çeviriyor, yoksa küçük nesneler gereğinden fazla cezalanıyordu. Formüldeki ikinci terim, modelin o tespitten ne kadar emin olduğunu skora katıyor. Üzerinde başka bir tespit taşıyan yüzeyler (masa, tezgâh, zemin) ile içinde başka bir obje bulunan kaplar (tabak, tepsi) asıl obje olamayacağı için skorları 0,45 ile çarpılıp geriye düşürülüyor.

Görseldeki en yüksek skorlu obje "asıl obje" kabul edilir; program iki durumda kullanıcıya tercih sunar: (1) en yüksek skor 0,55'in altındaysa, (2) ilk iki obje arasındaki skor farkı 0,08'den azsa. Tercih listesi sunulmadan önce adaylar sınıf adına göre tekilleştirilir — aksi hâlde birden fazla kez tespit edilen aynı obje (örn. beş köpekli bir görsel) kullanıcıya aynı isimle defalarca listeleniyordu. Tekilleştirme sonrası geriye tek aday kalıyorsa soru sorulmaz.

3. Kural Tabanlı Anahtar Kelime Üretimi

Seçilen yöntem: Apple'ın MobileCLIP2 metin kodlayıcısı modeli tercih edildi. Bu modelin tercih edilme sebebi, obje adını bir vektöre çevirip bu vektörü, LVIS'in 1205 sınıfının her biri için LLM ile üretilmiş 3'er kelimelik bir aday havuzuyla (1057 benzersiz kelime) verimli bir şekilde karşılaştırabilmesidir — en yakın 3 kelime bu şekilde seçiliyor.

Seçilen yöntemin diğer yöntemlerden farkı:

- **COCO'nun sabit 80 sınıfından farkı:** Projenin hedefi olabildiğince genel bir çözüm sunmaktı; COCO'nun 80 sabit sınıfı bu hedef için yetersiz kalıyor, yeni kategori eklemek yeniden eğitim gerektiriyor. Bizim yöntemimiz LVIS'in 1205 sınıfından türetilmiş bir havuzla, sınıf listesini sabitlemeden çalışma zamanında eşleştirme yapıyor.
- **WordNet'ten farkı:** WordNet sadece sözlüksel bir genelleme sunuyor, istenen bağlama uygun anahtar kelimeleri üretmiyor. Bizim yöntemimiz anlamsal benzerliğe dayandığı için bu tarz bağlamsal ilişkileri yakalayabiliyor.
- **MiniLM'den farkı:** MiniLM de bir embedding modeli, ama bizim havuzumuz LVIS'in 1205 sınıfından sistematik olarak türetildi. MobileCLIP, bu havuzdan uygun anahtar kelimeyi eşleştirmede MiniLM'e göre daha iyi sonuç verdiği için tercih edildi.
- **Model tabanlı yaklaşımlardan (VLM) farkı:** Görseli yeniden büyük bir görsel-dil modeline (VLM) verip obje hakkında betimleyici bir cümle almak da değerlendirildi; ancak bu yaklaşım projenin kapsamına göre gereksiz derecede ağır bir model gerektiriyor, üstelik elde edilen çıktı yine bir cümle olduğundan ondan da ayrıca anahtar kelime çıkarımı yapmak gerekecekti. YOLO zaten obje adını metin olarak verdiği için, görsele hiç dönmeden bu metni işleyen yöntemin daha sade ve performanslı olduğu görüldü.

4. Arama ve İçerik Süzme

Arama: DDGS (DuckDuckGo arama kütüphanesi) üzerinden obje adı + anahtar kelimeler + bağlam terimleriyle arama yapılıyor. DDGS tek seferde yeterli sonuç döndürmezse istek en fazla 5 kez, denemeler arası 1,5 saniye beklenerek tekrarlanıyor. Bulunan sayfalardan yeterli sayıda kullanılabilir içerik çıkmazsa, aynı sorguyla daha geniş bir arama tekrar yapılıyor. Toplanan içerikte hiç güvenilir/ansiklopedik kaynak (wikipedia.org/.edu/.gov) bulunamazsa, ek olarak "what is a X" biçiminde bir tanımlayıcı sorgu tetikleniyor.

İçerik süzme: trafilatura kütüphanesi ile ana metin (reklam/menü/altbilgi ayıklanmış hâliyle) çıkarılıyor, sonra art arda birkaç kurala kapıdan geçiyor: indirme başarılı olmalı, en az 200 kelime olmalı, sözlük/thesaurus sayfası olmamalı, obje adı metinde geçmeli, ticari/pazarlama kalıpları içermemeli, konu yoğunluğu yeterli olmalı. Ansiklopedik alan adları ticari-kalıp kontrolünden tamamen, yoğunluk eşliğinden ise kısmen muaf tutuluyor.

Neden ML tabanlı bir sınıflandırıcı kullanılmadı: Her kural tek, ölçülebilir bir sinyale dayanıyor ve dış bağımlılık gerektirmiyor. Ölçülen örnek: reklam/ticari sayfalarda obje adının geçme oranı %0,00-0,09 iken gerçek konu sayfalarında (Wikipedia gibi) %1,82-5,15 — aradaki 20 kat fark, basit bir eşğin yeterli olduğunu gösteriyor.

5. Çıkarımsal Özetleme Algoritması

Özetleme algoritması ve dayandığı temel: Özet bir dil modeliyle yeniden yazılmıyor; projeye özgü geliştirilen çıkarımsal (extractive) bir algoritmayla mevcut metinden en iyi cümleler seçilip birleştiriliyor. Algoritmanın temeli, cümleleri anahtar kelime frekansına göre puanlayan klasik Luhn yöntemine dayanıyor.

Neden üretken bir model kullanılmadı: Üretken özet dış bir servise bağımlılık ve doğrulanamaz/uydurma (hallüsinasyon) riski getirir. Çıkarımsal özet, seçilen her cümlelerin kaynağa birebir sadık olmasını garantiler.

Skorlama: Her cümle şu formülle puanlanıyor:

$$\text{skor} = 0.35 \times \text{frekans} + 0.2 \times \text{pozisyon} + 0.3 \times \text{uzunluk} - 0.15 \times (\text{nav/soru cezası}) + 0.05 \times (\text{bağlam bonusu})$$

- **Frekans:** cümledeki kelimelerin kaçının anahtar-kelime kümesiyle eşleştiği (en fazla 3 eşleşme sayılıyor, bir cümle obje adını tekrarlayarak yapay yüksek skor almasın diye). Cümlede objenin kendi adı hiç geçmiyorsa (sadece genel bir kategori kelimesi geçiyorsa) bu puan 0,6 ile çarpılıp düşürülüyor.
- **Pozisyon:** metnin başına yakın cümleleri hafifçe öne çıkarıyor — haber/ansiklopedi metinlerinde önemli bilginin genelde başta verilmesi varsayımına dayanan, özetlemede yaygın bir ek sezgisel kural.
- **Uzunluk:** 10-30 kelime arası cümleler tam puan alıyor, daha kısa/uzun cümleler kademeli düşük puanlanıyor — çok kısa cümleler bilgi taşımaz, çok uzun cümleler özeti gereksiz şişirir.
- **Nav/soru cezası:** Web sayfalarından kazınan metinde gerçek bilgi olmayan üç kalıp tespit edilip puanı düşürülüyor: cümle soru işaretiyle bitiyorsa (genelde bir SSS başlığıdır, bilgi cümlesi değil), "Page Contents"/"Skip to" gibi ifadelerle başlıyorsa (sayfa gezinme kalıntısıdır), ya da büyük kısmı art arda Büyük-Harfli-Kelime dizisinden oluşuyorsa (menü veya marka listesi olduğuna işaret eder). Bu üç sinyal, kazınan ham metindeki gürültüyü özete sızmadan önce ayıklıyor.
- **Bağlam bonusu:** Sohbet bağlamından gelen bir terim cümlede geçiyorsa küçük bir ek puan veriliyor.

Puanlamadan sonra ayrı bir adım olarak, seçilen cümleler arasında durak-kelimesi ayıklanmış içerik-kelimesi kümelerinin örtüşme oranı (overlap coefficient) %60'ı geçenler elenir — aynı bilginin farklı sayfalarda parafrazlanmış hali özetle iki kez yer almaz.

6. Veri Seti — LVIS

- **Neden LVIS seçildi:** LVIS 1205 sınıf içeriyor; sınıflar "sık" (f) / "orta" (c) / "nadir" (r) olarak etiketlenmiş, nadir sınıflar (337 tanesi) az örnekli olduğu için sıfırdan eğitim yerine açık-sözlüklü tespit tercih edilmesinin gerekçelerinden biriydi. Ayrıca her sınıf bir WordNet synset ID'sine sahip olarak geliyor — bu da anahtar kelime havuzunun kaynağı olarak kullanılabilecek ek bir referans sağlıyor.
- **Alternatif veri setlerinden farkı:** COCO'nun 80 sınıfına kıyasla LVIS çok daha geniş bir sınıf çeşitliliği sunuyor. Objects365 (365 sınıf, ~700 GB) ve Open Images V7'nin tam hali (600 sınıf, 561 GB) LVIS'ten daha az sınıf çeşitliliği sunarken çok daha büyük indirme/depolama gerektiriyor. V3Det (13.204 sınıf) sınıf

sayısında LVIS'i kat kat geçiyor, ama Ultralytics'in desteklemediği, ayrı bir eğitim altyapısı (mmdetection) gerektiren bir format. LVIS, sınıf çeşitliliği ile proje altyapısına uyum arasında en dengeli seçenek olduğu için tercih edildi.

7. Ön ve Ardıl İşlemler Özeti

- **Görsel okuma:** Dosya/URL baytları okunup modele verilecek görüntü dizisine çevriliyor.
 - **Tespit sonrası filtreleme:** Düşük güvenli tahminler elenir, kalanlar alan+güven skoruna göre sıralanır; taşıyıcı yüzey ya da kap olduğu anlaşılan tespitlerin skoru geriye düşürülür.
 - **Anahtar kelime sonrası dışlama:** Bir önceki objeye verilmiş kelimeler dışlanır.
 - **Arama öncesi temizlik:** Obje adındaki ayırt edici parantezler arama sorgusundan temizlenir — anahtar kelime çıkarımı bu temizlikten etkilenmez.
 - **Arama sonrası süzme:** İndirilemeyen, çok kısa, sözlük/tanım sayfası, obje adını hiç içermeyen, ticari/pazarlama kalıplı ya da düşük konu-yoğunluklu sayfalar elenir; kalan içerik yetersizse ya da hiç otorite kaynağı yoksa ek arama denir.
 - **Özet öncesi hazırlık:** Cümlelere ayırma; çok kısa cümlelerin ve tablo/kaynakça/bozuk-şablon parçalarının atılması.
 - **Özet sonrası temizlik:** Yakın-tekrar filtresi; cümlelerin orijinal sıraya göre yeniden dizilmesi.
-

8. Bilinen Kısıtlar

- **tespit riski:** YOLOE, LVIS görüntüleriyle hiç eğitilmedi, sınıfları sadece isim eşleştirmesiyle tanıyor. Bu yüzden özellikle nadir sınıflarda (337 tanesi) yanlış sınıflandırma riski daha yüksek.
- **Kapalı sınıf sözlüğü:** Sistem yalnızca LVIS'in 1205 sınıfını tanıyor; obje bu listede yoksa model onu en yakın ama yanlış bir sınıfa atıyor — "bilmiyorum" diyemiyor.
- **Kapalı anahtar kelime havuzu:** Objeye tam uyan bir kelime havuzda yoksa, model anlamca yakın ama yanlış kategoriye ait bir kelime seçebiliyor — özellikle bileşik isimlerde bu risk artıyor.
- **Web araştırmasının kaynak bağımlılığı:** Sistem bilgi üretmiyor (hâlüsinasyon riski taşıyor), ama güvenilir bir kaynak bulunamazsa özet düşük kaliteli içerikten üretilir ya da boş kalır.